

AGRICULTURE-SBD

David Menéndez Rodríguez

IES Azarquiel

alumno.1431653@ies-azarquiel.es

Abril 26, 2026

ABSTRACT

KEYWORDS

1. INTRODUCCIÓN Y DEFINICIÓN DEL PROBLEMA

2. ESTADO DEL ARTE

3. DATASET

4. METODOLOGÍA

4.1. ETL

El proceso ETL de este proyecto se estructuró en tres cuadernos Jupyter independientes, uno por tipología de dato: datos no estructurados (txt, jsonl), datos semi-estructurados (JSON/XML) y datos estructurados (CSV). Esta arquitectura modular permite que cada cuaderno sea ejecutado, revisado y mantenido de forma autónoma, sin que un error en el procesamiento de texto afecte al pipeline de los datos tabulares. También facilita el control de versiones en Git, ya que cada *commit* puede asociarse inequívocamente a un bloque funcional del pipeline. El resultado de los tres cuadernos es un conjunto de archivos en `data/processed/` que sirven como entrada única y validada para la fase de integración.

4.1.1. Datos no estructurados

Fuentes y estado inicial

Los datos no estructurados del proyecto procedían de dos fuentes con naturalezas distintas: el archivo `reportes_plagas.txt`, un fichero de texto plano con 100 informes agrícolas en lenguaje natural sin ninguna estructura formal, y `noticias_agricolas.jsonl`, un fichero en formato JSONL (*JSON Lines*) donde cada línea era un objeto JSON independiente con los campos titular, contenido, fecha, fuente y categoría.

Limpieza de texto crudo

Antes de aplicar cualquier técnica de NLP (*Natural Language Processing* — procesamiento del lenguaje natural), el texto de ambas fuentes fue sometido a un proceso de normalización. Se convirtió todo el contenido a minúsculas para evitar que la misma palabra ("Sequía" vs. "sequía") fuera tratada como dos entidades distintas por el modelo. A continuación se eliminaron los caracteres especiales y signos de puntuación mediante expresiones regulares, y se aplicó eliminación de *stop words* (palabras vacías de significado semántico como "el", "de", "que"). Esta limpieza previa es imprescindible: un modelo de sentimiento o un extractor de entidades que recibe texto sucio produce resultados con ruido estadístico que se propagan sin control a las fases posteriores.

Transformación: Ingeniería de características mediante NLP

En noticias_agricolas.jsonl: el objetivo era transformar el campo contenido, texto libre, en una variable numérica que los modelos de Machine Learning pudieran consumir. Se aplicó análisis de sentimiento con VADER (*Valence Aware Dictionary and sEntiment Reasoner*), un lexicón especializado en texto de dominio económico y noticioso que devuelve un *compound score* (una puntuación compuesta) en el rango $[-1,1]$, donde los valores negativos indican texto con connotación negativa (pérdidas, sequías, caída de precios) y los positivos indican connotación positiva (nuevas políticas, incremento de producción). Este método falló ya que estaba pensado para utilizarse en inglés por lo que se llevó a cabo un analizador con palabras clave de agricultura divididas en positivas y negativas en español hecho de manera manual. El resultado fue la columna `sentiment_compound` y su etiqueta derivada `sentiment_label` (positivo / negativo / neutro). Cada noticia quedó así representada por variables numéricas y categóricas directamente utilizables.

En reportes_plagas.txt: el reto era distinto. El archivo no tenía un esquema predefinido, por lo que fue necesario extraer entidades mediante patrones lingüísticos y expresiones regulares. Se identificaron y extrajeron como variables independientes: la fecha del reporte, el país y la región afectados, el cultivo implicado, el tipo_agente (plaga o enfermedad), el nombre concreto del agente (p. ej. "Barrenador del tallo", "Langosta", "Piricularia"), el nivel de severidad en escala cualitativa (baja / media / alta / crítica) y su equivalente numérico `severidad_num` (1 a 4), el área_ha afectada, el tipo de tratamiento aplicado y la `eficacia_pct` y `perdida_pct` resultantes. De este modo, 100 informes de texto libre se transformaron en una tabla estructurada de 100 filas y 15 columnas, directamente preparada para el modelo P2 de clasificación de riesgo.

4.1.2. Datos semi-estructurados

Fuentes y estado inicial

Los datos semi-estructurados provenían de dos archivos: `condiciones_climaticas.json`, un JSON anidado de 90.000 caracteres con registros de clima organizados en una jerarquía de país → región → año → variables meteorológicas y eventos extremos, y `politicas_agricolas.xml`, un documento XML con namespaces que contenía tres tipos de entidades distintas: subsidios agrícolas, regulaciones vigentes y acuerdos internacionales firmados por los 12 países del proyecto.

La característica común de ambas fuentes es que, aunque tienen cierta estructura (el JSON sigue un esquema y el XML respeta etiquetas), no son tablas planas: sus datos están **anidados en niveles jerárquicos** que los hacen incompatibles con el formato tabular que exigen los algoritmos de Machine Learning.

Limpieza

El JSON presentaba algunos valores nulos en campos opcionales de eventos extremos (cuando un año no registraba ningún evento de sequía). Para homogeneizar la estructura, se rellenaron estas ausencias con 0 antes del aplanamiento, lo que evita que pandas infiera tipos incorrectos durante la normalización. El XML contenía campos como vigente en la tabla de regulaciones que estaban vacíos en todas las filas del conjunto de datos, lo que se documentó como dato ausente en origen, sin imputación.

Transformación: Aplanamiento (Flattening)

Para `condiciones_climaticas.json`: se utilizó `pandas.json_normalize()`, una función que "aplana" estructuras JSON anidadas en una tabla bidimensional de filas y columnas. El resultado fue una tabla donde cada fila representa una combinación única de país × región × año, con variables climáticas continuas (temperatura promedio, máxima, mínima, precipitación total, humedad relativa, días con heladas, meses de estrés hídrico, índice de aridez) y contadores discretos de eventos extremos por tipo (granizo, helada tardía, incendios, inundación, ola de calor, sequía extrema, sequía moderada, sequía severa, tormenta severa). El campo original `eventos_str`, que almacenaba los eventos como una cadena de texto con separador | (p. ej. "sequia_severa|helada_tardia|incendios"),

fue *parseado* mediante `str.split()` y transformado en columnas binarias independientes, una por tipo de evento, lo que facilita enormemente su uso como *features* en los modelos.

Para `politicas_agricolas.xml`: se utilizó la librería `lxml` con `etree.parse()` para recorrer el árbol XML respetando los namespaces del documento. Las tres entidades del fichero — subsidios, regulaciones y acuerdos— se extrajeron en tres DataFrames independientes mediante iteración por nodos, dado que su estructura interna era heterogénea. `politicas_subsidios.csv` quedó con granularidad país × año; `politicas_regulaciones.csv` con granularidad país × tipo de regulación, incluyendo el año de implementación y las penalizaciones asociadas; y `politicas_acuerdos.csv` con granularidad país × acuerdo internacional, indicando si estaba firmado y el objetivo de reducción de emisiones cuando existía. Esta separación en tres tablas respeta la naturaleza semánticamente distinta de cada tipo de política y facilita su cruce posterior con los datasets de producción.

4.1.3. Datos estructurados

Fuentes y estado inicial

Los datos estructurados del proyecto comprenden cuatro archivos CSV con granularidades y temáticas distintas: `produccion_agricola.csv` (datos de producción por país, cultivo y año), `produccion_ganadera.csv` (producción por país, tipo de ganado y año), `precios_mercado.csv` (series de precios mensuales por país y producto) e `imagenes_metadata.csv` (metadatos de imágenes satelitales por país, región y fecha de captura). Los cuatro comparten el formato tabular, pero diferían en su nivel de calidad, en el tipo y cantidad de valores nulos presentes, y en las transformaciones necesarias para ser aptos para el modelado.

Limpieza de datos

Valores nulos: el análisis inicial reveló que el patrón de nulos era distinto en cada fuente. En `produccion_ganadera.csv`, el campo `produccion_leche_lit` presentaba nulos en todas las filas correspondientes a ganado porcino y avícola —aproximadamente un 40% del total—. Lejos de ser un error de datos, se trata de un **nulo estructural**: biológicamente, cerdos y aves no producen leche, por lo que eliminar esas filas habría supuesto perder información valiosa del resto de variables (cabezas de ganado, emisiones, eficiencia). Se optó por conservar los nulos y documentarlos con la columna derivada `flag_leche_no_aplica`, que permite a los modelos distinguir explícitamente esta ausencia de un dato realmente faltante.

En `precios_mercado.csv`, se identificaron valores fuera de rango en la columna `precio_usd_ton`, que fueron marcados con el flag binario `flag_precio_fuera_rango` (0/1) en lugar de eliminarse, preservando la integridad de la serie temporal para el modelo P4. En `produccion_agricola.csv` y `imagenes_metadata.csv` no se detectaron nulos no justificados tras la exploración inicial.

Duplicados y errores de formato: en `precios_mercado.csv` la columna `fecha` llegaba en formato de texto (string) con el patrón YYYY-MM-DD. Se convirtió a tipo `datetime` y se extrajeron las columnas `anio` y `mes` como variables enteras independientes, facilitando la construcción de *features* temporales sin necesidad de parsear la fecha en cada operación posterior. No se encontraron filas duplicadas en ninguno de los cuatro archivos.

Transformación: Ingeniería de Características

La fase de transformación de los CSV no se limitó a limpiar los datos en origen, sino que añadió **nuevas variables derivadas** que incorporan conocimiento de dominio y enriquecen la capacidad predictiva de los modelos.

En `produccion_agricola_processed.csv`: se calculó la columna `tendencia_5_anios`, que mide la tasa de cambio media del rendimiento por hectárea (`rendimiento_ton_ha`) en los cinco años anteriores a cada registro, usando una regresión lineal por grupo (país × cultivo). Este valor positivo o negativo captura la dirección estructural de la producción y es una de las *features* más relevantes para el Problema P1 (predicción de rendimiento) y P6 (recomendación de cultivos), ya que un modelo que ignora si un cultivo lleva años en declive en una región comete errores sistemáticos.

En `produccion_ganadera_processed.csv`: se calcularon dos métricas de eficiencia productiva. La `intensidad_emisiones` mide las toneladas de CO₂ equivalente emitidas por tonelada de carne producida (`emisiones / producción`). La `eficiencia_carne` es el ratio inverso (`producción / cabezas de ganado`), que expresa cuántas toneladas de carne se obtienen por animal. Sobre ambas se aplicó detección de valores extremos mediante el criterio del **rango intercuartílico (IQR)**, marcando los outliers con las columnas `flag_emision_extrema` y `flag_eficiencia_anomala`. Estos flags son directamente útiles para el Problema P5 (detección de anomalías en producción).

En `precios_mercado_processed.csv`: a partir del precio mensual se calcularon el `precio_min_mes` y `precio_max_mes` dentro de cada combinación país × producto × mes, y a partir de ambos se derivó el `spread_precio` (diferencia absoluta entre máximo y mínimo) y el `spread_pct` (spread relativo respecto al precio mínimo). También se codificó numéricamente la variable `tendencia_30_dias` (subiendo = 1, estable = 0, bajando = -1) en la columna `tendencia_30_dias_num`, convirtiendo una variable categórica ordinal en un entero directamente consumible por los modelos de series temporales del Problema P4.

En `imagenes_metadata_processed.csv`: se convirtieron las columnas de bandas espectrales disponibles (`banda_NIR`, `banda_RGB`, `banda_SWIR`) a variables binarias (0/1) a partir de la columna de texto `bandas_disponibles`, que en origen era una cadena del tipo "RGB, NIR, SWIR". Se añadió el flag `flag_ndvi_anomalo`, que marca imágenes con valores del índice NDVI (*Normalized Difference Vegetation Index* — índice de vegetación normalizado) fuera del rango esperado para la estación y región. Finalmente,

se creó la columna `imagen_valida` que combina calidad de imagen y cobertura de nubes para indicar si la imagen es apta para su uso en análisis posteriores.

4.1.4. Integración datasets

Al finalizar la fase de limpieza y preprocesado, el proyecto contaba con **10 datasets independientes** con naturalezas muy distintas entre sí. Las granularidades, es decir, el nivel de detalle de cada fila no eran compatibles: algunos datos estaban registrados a nivel de **región geográfica y año** (producción agrícola, condiciones climáticas), otros a nivel de **país y año** (subsidios, acuerdos internacionales) y otros con periodicidad **mensual** (precios de mercado). Antes de poder cruzar estas fuentes, se considera necesario alinearlas en una unidad de análisis común.

El objetivo de esta fase no era, en ningún caso, construir un único "superdataset" que lo contuviese todo. Mezclar datos con coberturas temporales dispares o con granularidades incompatibles, habría introducido ruido estadístico artificial y habría dificultado tanto el entrenamiento de los modelos como la interpretación de sus resultados. La estrategia adoptada fue, en cambio, **diseñar conjuntos de datos orientados a problema**: cada dataset maestro resultante está concebido para alimentar directamente uno o varios de los 6 problemas de Machine Learning definidos en el enunciado.

Agregaciones previas: alineando la granularidad (bloque PRE)

Antes de ejecutar los JOINS definitivos, fue necesario un bloque de agregaciones intermedias que transformó los datos brutos en tablas que sí podían cruzarse con coherencia.

- **Clima (`clima_pais_anio`):** El dataset original de condiciones climáticas estaba a nivel de región y año. Se agregó a nivel **país × año** mediante promedios para las variables continuas (temperatura, humedad, índice de aridez) y sumas para los contadores de eventos extremos (granizo, heladas tardías, sequías). La elección del estadístico no es arbitraria: promediar eventos extremos daría una imagen falsa de seguridad, mientras que sumarlos refleja la acumulación real de riesgo.
- **Subsidios, regulaciones y acuerdos internacionales:** Las tres tablas de políticas se pivotaron desde un formato largo (*long format*) a un formato tabular ancho (*wide format*), donde cada tipo de regulación o acuerdo se convierte en una columna

binaria (0/1). Esto permite que los modelos de Machine Learning consuman esta información directamente sin codificación adicional. El flag `tiene_subsidio_activo` se construyó de forma explícita para distinguir "sin subsidio" de "dato no disponible".

La estrategia de Tiers: calidad antes que exhaustividad

El núcleo de la decisión arquitectónica fue dividir los datasets resultantes en **dos niveles de fidelidad (Tiers)** según la calidad del solapamiento temporal y la cobertura geográfica.

Tier 1 — Alta Fidelidad agrupa los dos datasets maestros contruidos mediante JOINS encadenados:

- `master_agricola.csv` (1.200 filas × 51 columnas): una producción agrícola, clima, subsidios, regulaciones y acuerdos internacionales sobre el eje país × cultivo × año para el período 2011–2020. Alimenta los **Problemas P1, P5 y P6** (predicción de rendimiento, detección de anomalías y recomendación de cultivos).
- `master_ganadero.csv` (600 filas × 49 columnas): construido sobre el mismo eje temporal pero con tipo de ganado como dimensión específica. Alimenta el **Problema P3** (segmentación de países por patrones productivos).

Ambos datasets comparten el mismo período 2011–2020 y los 12-15 países del proyecto, lo que garantiza un **solapamiento temporal casi perfecto**. Los valores nulos (*NaN*) presentes en ambos están completamente justificados y documentados: un 16–33% en las variables climáticas corresponde a países reales que no disponen de datos en las fuentes originales (p. ej. Kenia, Rusia), y el 40% de `produccion_leche_lt` en el ganadero responde a una **imposibilidad biológica**, ya que las aves y los cerdos no producen leche. Para distinguir este tipo de ausencia estructural de un simple dato faltante, se añadió la columna `flag_leche_no_aplica`. Ninguno de los *NaN* presentes en el bloque de políticas (subsidios, regulaciones, acuerdos) es nulo: la cobertura es del 100%.

Tier 2 — Standalone comprende los datasets que se usarán directamente, sin integrarse en los masters:

- `precios_mercado_processed.csv`: serie temporal mensual que alimenta el **Problema P4** (predicción de precios de mercado). Su naturaleza temporal exige modelos específicos de series temporales que se benefician de trabajar sobre una tabla limpia y continua, sin el ruido que introduciría un JOIN con datos anuales.

- reportes_plagas_processed.csv: tabla de eventos de plagas que alimenta el **Problema P2** (clasificación de riesgo). Su estructura es independiente y autosuficiente para los modelos de clasificación previstos.

JOINS descartados: el coste de los datos ausentes

Una de las decisiones más relevantes del proceso fue **no ejecutar** dos JOINS que inicialmente parecían razonables.

El primero era cruzar las noticias agrícolas procesadas con los precios de mercado, con el objetivo de incorporar el sentimiento noticioso como *feature* del modelo de predicción de precios (P4). El análisis de cobertura demostró que solo el **22,9% de las combinaciones país × producto × mes** tenían una noticia asociada. Imputar el 77,1% restante como sentimiento "neutro" habría destruido la varianza de la variable y habría generado un modelo que aprende sobre el ruido en lugar de sobre la señal real. El coste de ese JOIN era mayor que su beneficio.

El segundo JOIN descartado era cruzar los metadatos de imágenes satelitales con el clima. Sin píxeles reales disponibles, solo metadatos como resolución, fecha de captura o índice de nubosidad, la integración no aportaba valor analítico significativo para el Problema P5, que trabaja directamente sobre la detección de anomalías en producción. Se preservó imagenes_metadata_processed.csv como dataset auxiliar para el EDA visual.

Inventario final de datasets

Tier 1 — Datasets maestros (alta fidelidad)

Dataset	Filas	Columnas	NaN justificados	Modelos ML
master_agricola.csv	1.200	51	Clima 33% (5 países sin datos), Precio 71% (6 cultivos sin precio histórico)	P1, P5, P6
master_ganadero.csv	600	49	Clima 17% (2 países sin datos), Leche 40% (estructural: especie no láctea)	P3

Tier 2 — Datasets standalone (uso directo)

Dataset	Filas	Columnas	Modelo ML
precios_mercado_processed.csv	864	15	P4 — Predicción de precios
reportes_plagas_processed.csv	100	15	P2 — Clasificación de riesgo de plagas
imagenes_metadata_processed.csv	600	~20	P5 — Auxiliar en detección de anomalías

Datasets auxiliares (solo EDA)

Dataset	Uso previsto
noticias_processed.csv	Correlación sentimiento ↔ precios en el análisis exploratorio
condiciones_climaticas_processed.csv	Fuente original; no se usa directamente en ML

5. RESULTADOS

6. VISUALIZACIÓN (POWERBI)

7. DISCUSIÓN

8. CONCLUSIONES

9. ANEXOS

