

AGRICULTURE-SBD

David Menéndez Rodríguez

IES Azarquiel

alumno.1431653@ies-azarquiel.es

Abril 26, 2026

ABSTRACT

KEYWORDS

1. INTRODUCCIÓN Y DEFINICIÓN DEL PROBLEMA

2. ESTADO DEL ARTE

3. DATASET

4. METODOLOGÍA

4.1. ETL

El proceso ETL de este proyecto se estructuró en tres cuadernos Jupyter independientes, uno por tipología de dato: datos no estructurados (txt, jsonl), datos semi-estructurados (JSON/XML) y datos estructurados (CSV). Esta arquitectura modular permite que cada cuaderno sea ejecutado, revisado y mantenido de forma autónoma, sin que un error en el procesamiento de texto afecte al pipeline de los datos tabulares. También facilita el control de versiones en Git, ya que cada *commit* puede asociarse inequívocamente a un bloque funcional del pipeline. El resultado de los tres cuadernos es un conjunto de archivos en `data/processed/` que sirven como entrada única y validada para la fase de integración.

4.1.1. Datos no estructurados

Fuentes y estado inicial

Los datos no estructurados del proyecto procedían de dos fuentes con naturalezas distintas: el archivo `reportes_plagas.txt`, un fichero de texto plano con 100 informes agrícolas en lenguaje natural sin ninguna estructura formal, y `noticias_agricolas.jsonl`, un fichero en formato JSONL (*JSON Lines*) donde cada línea era un objeto JSON independiente con los campos titular, contenido, fecha, fuente y categoría.

Limpieza de texto crudo

Antes de aplicar cualquier técnica de NLP (*Natural Language Processing* — procesamiento del lenguaje natural), el texto de ambas fuentes fue sometido a un proceso de normalización. Se convirtió todo el contenido a minúsculas para evitar que la misma palabra ("Sequía" vs. "sequía") fuera tratada como dos entidades distintas por el modelo. A continuación se eliminaron los caracteres especiales y signos de puntuación mediante expresiones regulares, y se aplicó eliminación de *stop words* (palabras vacías de significado semántico como "el", "de", "que"). Esta limpieza previa es imprescindible: un modelo de sentimiento o un extractor de entidades que recibe texto sucio produce resultados con ruido estadístico que se propagan sin control a las fases posteriores.

Transformación: Ingeniería de características mediante NLP

En noticias_agricolas.jsonl: el objetivo era transformar el campo contenido, texto libre, en una variable numérica que los modelos de Machine Learning pudieran consumir. Se aplicó análisis de sentimiento con VADER (*Valence Aware Dictionary and sEntiment Reasoner*), un lexicón especializado en texto de dominio económico y noticioso que devuelve un *compound score* (una puntuación compuesta) en el rango $[-1,1]$, donde los valores negativos indican texto con connotación negativa (pérdidas, sequías, caída de precios) y los positivos indican connotación positiva (nuevas políticas, incremento de producción). Este método falló ya que estaba pensado para utilizarse en inglés por lo que se llevó a cabo un analizador con palabras clave de agricultura divididas en positivas y negativas en español hecho de manera manual. El resultado fue la columna `sentiment_compound` y su etiqueta derivada `sentiment_label` (positivo / negativo / neutro). Cada noticia quedó así representada por variables numéricas y categóricas directamente utilizables.

En reportes_plagas.txt: el reto era distinto. El archivo no tenía un esquema predefinido, por lo que fue necesario extraer entidades mediante patrones lingüísticos y expresiones regulares. Se identificaron y extrajeron como variables independientes: la fecha del reporte, el país y la región afectados, el cultivo implicado, el tipo_agente (plaga o enfermedad), el nombre concreto del agente (p. ej. "Barrenador del tallo", "Langosta", "Piricularia"), el nivel de severidad en escala cualitativa (baja / media / alta / crítica) y su equivalente numérico `severidad_num` (1 a 4), el área_ha afectada, el tipo de tratamiento aplicado y la `eficacia_pct` y `perdida_pct` resultantes. De este modo, 100 informes de texto libre se transformaron en una tabla estructurada de 100 filas y 15 columnas, directamente preparada para el modelo P2 de clasificación de riesgo.

4.1.2. Datos semi-estructurados

Fuentes y estado inicial

Los datos semi-estructurados provenían de dos archivos: `condiciones_climaticas.json`, un JSON anidado de 90.000 caracteres con registros de clima organizados en una jerarquía de país → región → año → variables meteorológicas y eventos extremos, y `politicas_agricolas.xml`, un documento XML con namespaces que contenía tres tipos de entidades distintas: subsidios agrícolas, regulaciones vigentes y acuerdos internacionales firmados por los 12 países del proyecto.

La característica común de ambas fuentes es que, aunque tienen cierta estructura (el JSON sigue un esquema y el XML respeta etiquetas), no son tablas planas: sus datos están **anidados en niveles jerárquicos** que los hacen incompatibles con el formato tabular que exigen los algoritmos de Machine Learning.

Limpieza

El JSON presentaba algunos valores nulos en campos opcionales de eventos extremos (cuando un año no registraba ningún evento de sequía). Para homogeneizar la estructura, se rellenaron estas ausencias con 0 antes del aplanamiento, lo que evita que pandas infiera tipos incorrectos durante la normalización. El XML contenía campos como vigente en la tabla de regulaciones que estaban vacíos en todas las filas del conjunto de datos, lo que se documentó como dato ausente en origen, sin imputación.

Transformación: Aplanamiento (Flattening)

Para `condiciones_climaticas.json`: se utilizó `pandas.json_normalize()`, una función que "aplana" estructuras JSON anidadas en una tabla bidimensional de filas y columnas. El resultado fue una tabla donde cada fila representa una combinación única de país × región × año, con variables climáticas continuas (temperatura promedio, máxima, mínima, precipitación total, humedad relativa, días con heladas, meses de estrés hídrico, índice de aridez) y contadores discretos de eventos extremos por tipo (granizo, helada tardía, incendios, inundación, ola de calor, sequía extrema, sequía moderada, sequía severa, tormenta severa). El campo original `eventos_str`, que almacenaba los eventos como una cadena de texto con separador | (p. ej. "sequia_severa|helada_tardia|incendios"),

fue *parseado* mediante `str.split()` y transformado en columnas binarias independientes, una por tipo de evento, lo que facilita enormemente su uso como *features* en los modelos.

Para `politicas_agricolas.xml`: se utilizó la librería `lxml` con `etree.parse()` para recorrer el árbol XML respetando los namespaces del documento. Las tres entidades del fichero — subsidios, regulaciones y acuerdos— se extrajeron en tres DataFrames independientes mediante iteración por nodos, dado que su estructura interna era heterogénea. `politicas_subsidios.csv` quedó con granularidad país × año; `politicas_regulaciones.csv` con granularidad país × tipo de regulación, incluyendo el año de implementación y las penalizaciones asociadas; y `politicas_acuerdos.csv` con granularidad país × acuerdo internacional, indicando si estaba firmado y el objetivo de reducción de emisiones cuando existía. Esta separación en tres tablas respeta la naturaleza semánticamente distinta de cada tipo de política y facilita su cruce posterior con los datasets de producción.

4.1.3. Datos estructurados

Fuentes y estado inicial

Los datos estructurados del proyecto comprenden cuatro archivos CSV con granularidades y temáticas distintas: `produccion_agricola.csv` (datos de producción por país, cultivo y año), `produccion_ganadera.csv` (producción por país, tipo de ganado y año), `precios_mercado.csv` (series de precios mensuales por país y producto) e `imagenes_metadata.csv` (metadatos de imágenes satelitales por país, región y fecha de captura). Los cuatro comparten el formato tabular, pero diferían en su nivel de calidad, en el tipo y cantidad de valores nulos presentes, y en las transformaciones necesarias para ser aptos para el modelado.

Limpieza de datos

Valores nulos: el análisis inicial reveló que el patrón de nulos era distinto en cada fuente. En `produccion_ganadera.csv`, el campo `produccion_leche_lit` presentaba nulos en todas las filas correspondientes a ganado porcino y avícola —aproximadamente un 40% del total—. Lejos de ser un error de datos, se trata de un **nulo estructural**: biológicamente, cerdos y aves no producen leche, por lo que eliminar esas filas habría supuesto perder información valiosa del resto de variables (cabezas de ganado, emisiones, eficiencia). Se optó por conservar los nulos y documentarlos con la columna derivada `flag_leche_no_aplica`, que permite a los modelos distinguir explícitamente esta ausencia de un dato realmente faltante.

En `precios_mercado.csv`, se identificaron valores fuera de rango en la columna `precio_usd_ton`, que fueron marcados con el flag binario `flag_precio_fuera_rango` (0/1) en lugar de eliminarse, preservando la integridad de la serie temporal para el modelo P4. En `produccion_agricola.csv` y `imagenes_metadata.csv` no se detectaron nulos no justificados tras la exploración inicial.

Duplicados y errores de formato: en `precios_mercado.csv` la columna `fecha` llegaba en formato de texto (string) con el patrón YYYY-MM-DD. Se convirtió a tipo `datetime` y se extrajeron las columnas `anio` y `mes` como variables enteras independientes, facilitando la construcción de *features* temporales sin necesidad de parsear la fecha en cada operación posterior. No se encontraron filas duplicadas en ninguno de los cuatro archivos.

Transformación: Ingeniería de Características

La fase de transformación de los CSV no se limitó a limpiar los datos en origen, sino que añadió **nuevas variables derivadas** que incorporan conocimiento de dominio y enriquecen la capacidad predictiva de los modelos.

En `produccion_agricola_processed.csv`: se calculó la columna `tendencia_5_anios`, que mide la tasa de cambio media del rendimiento por hectárea (`rendimiento_ton_ha`) en los cinco años anteriores a cada registro, usando una regresión lineal por grupo (país × cultivo). Este valor positivo o negativo captura la dirección estructural de la producción y es una de las *features* más relevantes para el Problema P1 (predicción de rendimiento) y P6 (recomendación de cultivos), ya que un modelo que ignora si un cultivo lleva años en declive en una región comete errores sistemáticos.

En `produccion_ganadera_processed.csv`: se calcularon dos métricas de eficiencia productiva. La `intensidad_emisiones` mide las toneladas de CO₂ equivalente emitidas por tonelada de carne producida (`emisiones / producción`). La `eficiencia_carne` es el ratio inverso (`producción / cabezas de ganado`), que expresa cuántas toneladas de carne se obtienen por animal. Sobre ambas se aplicó detección de valores extremos mediante el criterio del **rango intercuartílico (IQR)**, marcando los outliers con las columnas `flag_emision_extrema` y `flag_eficiencia_anomala`. Estos flags son directamente útiles para el Problema P5 (detección de anomalías en producción).

En `precios_mercado_processed.csv`: a partir del precio mensual se calcularon el `precio_min_mes` y `precio_max_mes` dentro de cada combinación país × producto × mes, y a partir de ambos se derivó el `spread_precio` (diferencia absoluta entre máximo y mínimo) y el `spread_pct` (spread relativo respecto al precio mínimo). También se codificó numéricamente la variable `tendencia_30_dias` (subiendo = 1, estable = 0, bajando = -1) en la columna `tendencia_30_dias_num`, convirtiendo una variable categórica ordinal en un entero directamente consumible por los modelos de series temporales del Problema P4.

En `imagenes_metadata_processed.csv`: se convirtieron las columnas de bandas espectrales disponibles (`banda_NIR`, `banda_RGB`, `banda_SWIR`) a variables binarias (0/1) a partir de la columna de texto `bandas_disponibles`, que en origen era una cadena del tipo "RGB, NIR, SWIR". Se añadió el flag `flag_ndvi_anomalo`, que marca imágenes con valores del índice NDVI (*Normalized Difference Vegetation Index* — índice de vegetación normalizado) fuera del rango esperado para la estación y región. Finalmente,

se creó la columna `imagen_valida` que combina calidad de imagen y cobertura de nubes para indicar si la imagen es apta para su uso en análisis posteriores.

4.1.4. Integración datasets

Al finalizar la fase de limpieza y preprocesado, el proyecto contaba con **10 datasets independientes** con naturalezas muy distintas entre sí. Las granularidades, es decir, el nivel de detalle de cada fila no eran compatibles: algunos datos estaban registrados a nivel de **región geográfica y año** (producción agrícola, condiciones climáticas), otros a nivel de **país y año** (subsidios, acuerdos internacionales) y otros con periodicidad **mensual** (precios de mercado). Antes de poder cruzar estas fuentes, se considera necesario alinearlas en una unidad de análisis común.

El objetivo de esta fase no era, en ningún caso, construir un único "superdataset" que lo contuviese todo. Mezclar datos con coberturas temporales dispares o con granularidades incompatibles, habría introducido ruido estadístico artificial y habría dificultado tanto el entrenamiento de los modelos como la interpretación de sus resultados. La estrategia adoptada fue, en cambio, **diseñar conjuntos de datos orientados a problema**: cada dataset maestro resultante está concebido para alimentar directamente uno o varios de los 6 problemas de Machine Learning definidos en el enunciado.

Agregaciones previas: alineando la granularidad (bloque PRE)

Antes de ejecutar los JOINS definitivos, fue necesario un bloque de agregaciones intermedias que transformó los datos brutos en tablas que sí podían cruzarse con coherencia.

- **Clima (`clima_pais_anio`):** El dataset original de condiciones climáticas estaba a nivel de región y año. Se agregó a nivel **país × año** mediante promedios para las variables continuas (temperatura, humedad, índice de aridez) y sumas para los contadores de eventos extremos (granizo, heladas tardías, sequías). La elección del estadístico no es arbitraria: promediar eventos extremos daría una imagen falsa de seguridad, mientras que sumarlos refleja la acumulación real de riesgo.
- **Subsidios, regulaciones y acuerdos internacionales:** Las tres tablas de políticas se pivotaron desde un formato largo (*long format*) a un formato tabular ancho (*wide format*), donde cada tipo de regulación o acuerdo se convierte en una columna

binaria (0/1). Esto permite que los modelos de Machine Learning consuman esta información directamente sin codificación adicional. El flag `tiene_subsidio_activo` se construyó de forma explícita para distinguir "sin subsidio" de "dato no disponible".

La estrategia de Tiers: calidad antes que exhaustividad

El núcleo de la decisión arquitectónica fue dividir los datasets resultantes en **dos niveles de fidelidad (Tiers)** según la calidad del solapamiento temporal y la cobertura geográfica.

Tier 1 — Alta Fidelidad agrupa los dos datasets maestros contruidos mediante JOINS encadenados:

- `master_agricola.csv` (1.200 filas × 51 columnas): una producción agrícola, clima, subsidios, regulaciones y acuerdos internacionales sobre el eje país × cultivo × año para el período 2011–2020. Alimenta los **Problemas P1, P5 y P6** (predicción de rendimiento, detección de anomalías y recomendación de cultivos).
- `master_ganadero.csv` (600 filas × 49 columnas): construido sobre el mismo eje temporal pero con tipo de ganado como dimensión específica. Alimenta el **Problema P3** (segmentación de países por patrones productivos).

Ambos datasets comparten el mismo período 2011–2020 y los 12-15 países del proyecto, lo que garantiza un **solapamiento temporal casi perfecto**. Los valores nulos (*NaN*) presentes en ambos están completamente justificados y documentados: un 16–33% en las variables climáticas corresponde a países reales que no disponen de datos en las fuentes originales (p. ej. Kenia, Rusia), y el 40% de `produccion_leche_lt` en el ganadero responde a una **imposibilidad biológica**, ya que las aves y los cerdos no producen leche. Para distinguir este tipo de ausencia estructural de un simple dato faltante, se añadió la columna `flag_leche_no_aplica`. Ninguno de los *NaN* presentes en el bloque de políticas (subsidios, regulaciones, acuerdos) es nulo: la cobertura es del 100%.

Tier 2 — Standalone comprende los datasets que se usarán directamente, sin integrarse en los masters:

- `precios_mercado_processed.csv`: serie temporal mensual que alimenta el **Problema P4** (predicción de precios de mercado). Su naturaleza temporal exige modelos específicos de series temporales que se benefician de trabajar sobre una tabla limpia y continua, sin el ruido que introduciría un JOIN con datos anuales.

- reportes_plagas_processed.csv: tabla de eventos de plagas que alimenta el **Problema P2** (clasificación de riesgo). Su estructura es independiente y autosuficiente para los modelos de clasificación previstos.

JOINS descartados: el coste de los datos ausentes

Una de las decisiones más relevantes del proceso fue **no ejecutar** dos JOINS que inicialmente parecían razonables.

El primero era cruzar las noticias agrícolas procesadas con los precios de mercado, con el objetivo de incorporar el sentimiento noticioso como *feature* del modelo de predicción de precios (P4). El análisis de cobertura demostró que solo el **22,9% de las combinaciones país × producto × mes** tenían una noticia asociada. Imputar el 77,1% restante como sentimiento "neutro" habría destruido la varianza de la variable y habría generado un modelo que aprende sobre el ruido en lugar de sobre la señal real. El coste de ese JOIN era mayor que su beneficio.

El segundo JOIN descartado era cruzar los metadatos de imágenes satelitales con el clima. Sin píxeles reales disponibles, solo metadatos como resolución, fecha de captura o índice de nubosidad, la integración no aportaba valor analítico significativo para el Problema P5, que trabaja directamente sobre la detección de anomalías en producción. Se preservó imagenes_metadata_processed.csv como dataset auxiliar para el EDA visual.

Inventario final de datasets

Tier 1 — Datasets maestros (alta fidelidad)

Dataset	Filas	Columnas	NaN justificados	Modelos ML
master_agricola.csv	1.200	51	Clima 33% (5 países sin datos), Precio 71% (6 cultivos sin precio histórico)	P1, P5, P6
master_ganadero.csv	600	49	Clima 17% (2 países sin datos), Leche 40% (estructural: especie no láctea)	P3

Tier 2 — Datasets standalone (uso directo)

Dataset	Filas	Columnas	Modelo ML
precios_mercado_processed.csv	864	15	P4 — Predicción de precios
reportes_plagas_processed.csv	100	15	P2 — Clasificación de riesgo de plagas
imagenes_metadata_processed.csv	600	~20	P5 — Auxiliar en detección de anomalías

Datasets auxiliares (solo EDA)

Dataset	Uso previsto
noticias_processed.csv	Correlación sentimiento ↔ precios en el análisis exploratorio
condiciones_climaticas_processed.csv	Fuente original; no se usa directamente en ML

4.2. EDA

4.2.1 Fotografía Inicial y Calidad del Dato

El primer paso del EDA consistió en caracterizar con precisión los seis conjuntos de datos antes de realizar cualquier transformación. La siguiente tabla recoge la ficha de identidad de cada dataset: dimensiones, porcentaje de valores nulos y su ventana temporal.

Dataset	Filas	Columnas	% NaN	Período	Granularidad
master_agricola	1.200	51	16,6 %	2011 – 2020	País × Cultivo × Año
master_ganadero	600	49	7,3 %	2011 – 2020	País × Tipo ganado × Año
precios_mercado	864	15	0 %	2021 – 2022	País × Producto × Fecha
reportes_plagas	100	15	0 %	2020 – 2022	País × Cultivo × Fecha
noticias	60	14	0 %	2021 – 2023	Noticia × Fecha
imagenes_metadata	250	23	0 %	2020 – 2033 (*)	País × Año × Banda

(*) El dataset de imágenes incluye registros con fechas hasta 2033. Se trata de proyecciones sobre años futuros, no imágenes satelitales reales; esta decisión de diseño se asume conscientemente dado el tamaño reducido del dataset y se documenta aquí para evitar interpretaciones erróneas en la fase de modelado.

Cabe destacar que los cuatro datasets complementarios (precios, plagas, noticias e imágenes) presentan un 0 % de valores nulos y están listos para su uso directo.

Los nulos se concentran exclusivamente en los datasets maestros, donde alcanzan el 16,6 % y el 7,3 % respectivamente.




Figura 4.2.1. Mapa de nulos

Análisis del mapa de nulos

La inspección detallada de los valores ausentes en master_agricola y master_ganadero reflejada en la Figura 1 reveló que el 100 % de los NaN responden a causas lógicas documentadas y no a errores de captura. Se identificaron tres familias de nulos estructurales, cada una con una estrategia de tratamiento diferenciada:

Nulos de precio histórico (master_agricola, 70,8 % en columnas precio_hist_*):
Seis de los diez cultivos analizados —Algodón, Café, Caña de azúcar, Cebada, Girasol y Té— no cotizan en los mercados de referencia de este dataset. Su ausencia no es un dato faltante sino una ausencia estructural. Estrategia: no imputar. Estas columnas quedan excluidas del modelo P1 y solo se usarán para los cuatro cultivos con datos confirmados (Trigo, Maíz, Soja, Arroz).

Nulos de producción de leche (master_ganadero, 40 % en produccion_leche_lt):
El 40 % corresponde exactamente a las especies porcino y avícola, para las que esta métrica carece de sentido biológico. El dataset ya incorpora la variable indicadora

flag_leche_no_aplica, que los modelos podrán utilizar directamente. Estrategia: no imputar; usar el flag como feature informativa.

Nulos climáticos (master_agricola ~33 %, master_ganadero ~17 %):

El patrón geográfico es inequívoco: los valores ausentes se concentran en Kenia y Rusia en el dataset agrícola, y en España en el ganadero, todos ellos sin datos climáticos en las fuentes de origen. Al tratarse de países concretos y no de registros aleatorios, la imputación por vecindad geográfica es la estrategia más coherente. Estrategia: aplicar KNNImputer (imputación por los k vecinos más próximos en el espacio de variables geográficas) antes de la partición train/test, para evitar introducir información del conjunto de validación.

Más allá de los valores nulos, el análisis inicial detectó dos restricciones de diseño que condicionan la arquitectura de todos los modelos de la Fase 3 y que deben quedar explícitamente documentadas.

La primera es un gap temporal: los datasets de producción (master_agricola y master_ganadero) cubren el período 2011–2020, mientras que los datasets de contexto (precios_mercado y noticias) arrancan en 2021. No existe solapamiento entre ambas capas. Cualquier enriquecimiento cruzado entre producción histórica y precios o noticias requeriría asumir que las relaciones estadísticas detectadas en el pasado se mantienen estables (supuesto de estacionariedad), lo que no puede verificarse con los datos disponibles. Esta restricción fue determinante para la decisión de no realizar joins entre los datasets maestros y los complementarios.

La segunda restricción es una asimetría geográfica: master_agricola cubre 15 países, master_ganadero y precios_mercado cubren 12 (sin Italia, Canadá ni Rusia), y reportes_plagas únicamente 8 (excluye además España, México y Nueva Zelanda).

Como consecuencia directa, los modelos P2 (riesgo de plagas) y P6 (recomendación de cultivos) solo podrán entrenarse y validarse sobre el subconjunto de 8 países cubiertos por reportes_plagas; cualquier inferencia sobre los 7 países restantes constituirá extrapolación no validada.

Finalmente, la doble estructura de los datos —temporal (10 años) y geográfica (hasta 15 países)— introduce un riesgo de data leakage si se aplica validación cruzada K-Fold aleatoria estándar: el modelo podría "ver" datos del año 2019 de un país para predecir el año 2015 del mismo país, inflando artificialmente las métricas. La estrategia de validación que aborda esta amenaza se detalla en el apartado 4.2.4.

4.2.2 Análisis Univariante: Distribuciones y Transformaciones

El análisis de las distribuciones individuales de las variables perseguía un objetivo concreto: identificar qué transformaciones de escala son necesarias antes de entrenar los modelos. Una variable con fuerte sesgo a la derecha no es solo un problema estético; en un modelo de Regresión Lineal, los valores extremos ejercen una influencia desproporcionada sobre la estimación de los coeficientes, arrastrando la recta de regresión hacia los outliers y penalizando la predicción en el rango central, que es donde se concentra la mayoría de los datos. En modelos basados en distancias —como KNN o SVM— el problema es análogo: un país que produce 50 millones de toneladas domina la distancia euclidiana frente a uno que produce 500.000, aunque ambos compartan el mismo patrón de eficiencia relativa.




Figura 4.2.2.A. - Histograma variables productivas agrícola

Sector Agrícola

El examen de las variables productivas del dataset master_agricola —ilustrado en la Figura 4.2.2.A— puso de manifiesto un sesgo a la derecha marcado en produccion_ton y superficie_hectareas, con distribuciones de cola larga donde unos pocos países de gran escala (China, Estados Unidos, India) desplazan la media muy por encima de la mediana. La variable rendimiento_ton_ha presenta un patrón mixto: bimodal a nivel

global, pero perfectamente estratificado cuando se segmenta por cultivo —hallazgo que se desarrolla en el apartado 4.2.3 al abordar el Problema 1.

La solución aplicada es la transformación $\log_{1p}()$, definida como $\log(1 + x)$. El uso de la variante con +1 garantiza que los valores cero —presentes en registros sin producción registrada— no generen valores indefinidos. La transformación comprime la escala de forma no lineal: reduce el peso de los valores extremos sin eliminarlos, aproximando la distribución a la normalidad y estabilizando la varianza. Las variables transformadas en `master_agricola` son: `rendimiento_ton_ha`, `produccion_ton` y `superficie_hectareas`.




Figura 4.2.2.B. - Histograma variables ganaderas

Sector Ganadero

El dataset `master_ganadero` reproduce el mismo patrón distribucional, como se observa en la Figura 4.2.2.B. Las variables `cabezas_ganado` y `produccion_carne_ton` concentran valores extremos en los países de cría intensiva a gran escala (principalmente China, Brasil y Estados Unidos para bovino y porcino), generando distribuciones con sesgo derecho severo. Las variables derivadas `intensidad_emisiones` y `eficiencia_carne` —calculadas como ratios respecto a la producción— muestran un sesgo más moderado, pero igualmente incompatible con los supuestos de linealidad. La variable `emisiones_ch4_ton_co2eq` presenta además outliers marcados correspondientes a episodios de contaminación extrema en ganadería bovina, que se tratan en detalle en el Problema 5. Las variables transformadas en `master_ganadero` mediante $\log_{1p}()$ son: `cabezas_ganado`, `produccion_carne_ton`, `emisiones_ch4_ton_co2eq`, `intensidad_emisiones` y `eficiencia_carne`.

Señal de Alerta: Variables de Distribución Uniforme

Un hallazgo inesperado del análisis univariante merece atención explícita. Las variables `fertilizantes_kg_ha` y `agua_riego_m3_ha` muestran una distribución prácticamente rectangular: los valores se distribuyen de forma uniforme dentro de un rango fijo, sin la estructura de picos y colas que cabría esperar en datos de campo reales. Este patrón es característico de variables generadas sintéticamente mediante muestreo aleatorio uniforme, donde cada valor del rango tiene la misma probabilidad de aparecer independientemente del cultivo o el país.

La implicación para el modelado es importante: un modelo entrenado sobre estas variables puede aprender a "encajar" la uniformidad de los predictores y obtener métricas de evaluación artificialmente buenas en validación, sin que ello refleje una capacidad predictiva real. Por esta razón, los resultados del Problema 1 que involucren estas variables deben interpretarse con cautela, y cualquier mejora en las métricas al incluirlas debe contrastarse mediante tests de permutación o análisis de importancia de features antes de asumir que aportan señal genuina.

4.2.3 Análisis por Problema de Negocio

Una vez caracterizadas las distribuciones individuales, el EDA avanzó hacia un análisis orientado a hipótesis: para cada uno de los seis problemas de negocio planteados en el enunciado, se formuló una pregunta de investigación, se buscó evidencia en los datos y se extrajo una directriz concreta para el diseño del modelo correspondiente.

Problema 1 — Predicción de Rendimiento Agrícola

Hipótesis de partida: si el rendimiento agrícola estuviera determinado principalmente por variables climáticas continuas —temperatura, precipitación, humedad—, una Regresión Lineal múltiple aplicada al dataset completo debería capturar esa relación y obtener un coeficiente de determinación R^2 razonable.

El análisis bivalente refutó esta hipótesis de forma contundente. Como ilustra la Figura 4.2.3.A, el rendimiento medido en toneladas por hectárea no sigue una distribución continua homogénea: está completamente estratificado por el tipo de cultivo. La Caña de azúcar opera en un rango de 60–80 ton/ha, mientras que el Trigo y la Cebada apenas superan las 3–5 ton/ha. No existe ninguna variable climática que explique por sí sola esa diferencia de 15 veces en el valor central; es la naturaleza agronómica del cultivo la que fija el orden de magnitud del rendimiento, y las variables continuas actúan como moduladores dentro de ese rango fijo.




Figura 4.2.3.A. - Rendimiento por cultivo

Decisión para ML — Problema 1: se descarta la Regresión Lineal global como modelo base útil. Se recomienda el uso de modelos basados en árboles (Random Forest, XGBoost), que manejan de forma natural las particiones categóricas. Como feature de ingeniería se creará la variable `rendimiento_medio_pais_cultivo` —media histórica de rendimiento para cada par (país, cultivo)—, que actúa como estimación de base antes de ver el dato concreto. Adicionalmente, la variable `anio` se incluirá como predictor numérico continuo para capturar la tendencia secular de mejora tecnológica en rendimiento (tecnificación, semillas mejoradas, mecanización) a lo largo del período 2011–2020.

Problema 2 — Clasificación de Riesgo de Plagas

Hipótesis de partida: si las condiciones climáticas y sanitarias adversas se reflejan en las noticias antes de que los brotes ocurran, el análisis de sentimiento de las noticias podría anticipar un aumento en los reportes de plagas.




Figura 4.2.3.B – Dashboard noticias

El análisis de sentimiento del corpus de 60 noticias, reflejado en la Figura 4.2.3.B reveló un sesgo positivo generalizado: el 71,7 % de las noticias fueron clasificadas como positivas por el modelo, sumado a un score de sentimiento con mediana de 0.35, incluyendo noticias de categorías como clima o sanidad que intuitivamente deberían asociarse con un tono neutral o negativo. Este sesgo es esperable en modelos de sentimiento preentrenados sobre corpus generales —típicamente dominados por texto comercial y social— y debe tenerse en cuenta al interpretar la variable. El hallazgo clave emergió al introducir un desfase temporal (lag) de dos meses entre el score de sentimiento negativo y la frecuencia de reportes de plagas. Como muestra la Figura 4.2.3.C, los picos de noticias negativas de categoría clima y sanidad correlacionan con un coeficiente $r = 0,603$ con un incremento en los reportes de plagas registrado dos meses después. Esta correlación, moderada-alta y estadísticamente interpretable, sugiere que las noticias funcionan como señal de alerta temprana: el deterioro de las condiciones climáticas y sanitarias se comunica en los medios antes de que el brote se materialice sobre el terreno.




Figura 4.2.3.C – Noticias vs plagas

La Figura 4.2.3.C presenta un gráfico de líneas con doble eje temporal. El eje izquierdo recoge el número de noticias negativas de categoría clima y sanidad; el eje derecho, el número de reportes de plagas registrados ese mes. La inspección visual del gráfico muestra que las barras rojas (noticias negativas) tienden a coincidir con los picos de la línea morada (brotes de plagas) en el mismo período o en el mes inmediatamente siguiente, sin que se observe un desfase sistemático y estable de dos meses a lo largo de toda la serie. Este matiz es relevante y obliga a una decisión metodológica prudente.

Si bien el cálculo estadístico sobre la serie completa arrojó la correlación máxima en lag-2 ($r = 0,603$), el tamaño de la muestra —60 noticias distribuidas en 24 meses, con apenas 4–5 eventos negativos en todo el período— no proporciona suficiente señal para validar ese desfase como una regularidad causal robusta. Elevar un lag-2 observado sobre tan pocos puntos a variable de entrada fija del modelo sería sobreajustar el pipeline a un artefacto estadístico de la muestra. Por esta razón, se opta por trabajar con lag-0: la señal de sentimiento negativo del mes en curso se incorpora directamente como feature del clasificador, sin introducir un desplazamiento temporal que el volumen de datos no puede respaldar con garantías. Esta decisión es más conservadora, más reproducible y más honesta con las limitaciones del dataset.

Decisión para ML — Problema 2: la variable `sentimiento_negativo_mes` (score medio de sentimiento negativo de las noticias de clima y sanidad del mes en curso, sin desfase) se integrará como feature del clasificador de riesgo de plagas. Se descarta `lag_sentimiento_2m` como variable de entrada principal dado el tamaño insuficiente de la muestra para validar ese desfase de forma robusta. Dado que el dataset `reportes_plagas` cuenta únicamente con 100 registros distribuidos en 8 países, la variable objetivo se binarizará (riesgo bajo vs. riesgo alto/crítico) para evitar clases vacías. Si se mantienen las cuatro categorías originales, se aplicará `class_weight='balanced'` o sobremuestreo con SMOTE (técnica que genera ejemplos sintéticos de las clases minoritarias interpolando entre observaciones reales). La validación se realizará con `StratifiedKFold` para garantizar que todas las clases estén representadas en cada partición.

Problema 3 — Sostenibilidad Ganadera

Hipótesis de partida: los sistemas ganaderos más eficientes —aquellos que producen más carne por cabeza de ganado— deberían generar menos emisiones por tonelada producida, ya que necesitan menos animales para el mismo output. El EDA refutó esta hipótesis y reveló la paradoja opuesta: como se aprecia en la Figura 4.2.3.D, la correlación entre `eficiencia_carne` e `intensidad_emisiones` es positiva. Los países y sistemas con mayor producción de carne por cabeza presentan también una mayor intensidad de emisiones Co_2 por tonelada. La explicación reside en la especie, no en la eficiencia del sistema: el bovino, que concentra los registros de mayor eficiencia productiva individual, genera una cantidad de metano por proceso digestivo (fermentación entérica) que ninguna mejora en la ratio de conversión puede compensar. La avicultura, en el extremo opuesto, presenta una huella de carbono residual independientemente de la escala de producción.




Figura 4.3.2.D – Eficiencia carne vs emisiones

La Figura 4.2.3.D muestra el diagrama de dispersión de eficiencia_carne (eje X, toneladas de carne por cabeza de ganado) frente a intensidad_emisiones (eje Y, toneladas de CO₂eq por tonelada de carne producida), con cada punto coloreado por tipo de ganado. La nube de puntos del bovino (rojo) se posiciona en la esquina superior derecha —alta eficiencia, alta intensidad emisora— mientras que la avicultura (azul) se agrupa en la esquina inferior izquierda. Porcino, ovino y caprino ocupan posiciones intermedias. Este gráfico demuestra visualmente que la especie ganadera es la variable más discriminante para la segmentación de países: dos países con el mismo volumen de producción pueden pertenecer a clústeres de sostenibilidad radicalmente distintos según su mix de especies.

Decisión para ML — Problema 3: el algoritmo de clustering (K-Means o DBSCAN) debe operar sobre las variables ya relativizadas —intensidad_emisiones y eficiencia_carne— para que los grupos reflejen el modelo productivo del país y no su tamaño absoluto (China y Brasil son outliers de volumen que distorsionarían cualquier agrupación basada en valores absolutos). La variable flag_emision_extrema se incluirá como feature binaria adicional. Se anticipa una solución de 3 clústeres: países de bajo impacto (dominio avícola/ovino), impacto medio (mix equilibrado) y alto impacto (dominio bovino intensivo).

Problema 4 — Predicción de Precios de Mercado

Hipótesis de partida: el precio de un producto agrícola y el volumen operado en el mercado deberían contener información suficiente para predecir la volatilidad futura de ese precio. El análisis de correlaciones sobre precios_mercado —recogido en la Figura 4.2.3.E— desmontó esta hipótesis en dos pasos. Primero, la correlación entre precio medio y volumen operado es prácticamente nula ($r = -0,02$): conocer cuántas unidades se han negociado no aporta información sobre el nivel de precios, lo que invalida el volumen como predictor directo. Segundo, el spread absoluto (diferencia entre precio máximo y mínimo del período) correlaciona fuertemente con el precio base, pero de forma artificial: los productos más caros —como la Carne bovina— tienen spreads nominalmente mayores en términos absolutos, sin que eso implique mayor volatilidad relativa. Incluir el spread absoluto como feature introduciría un sesgo sistemático hacia los productos de precio elevado.




Figura 4.3.2.E – Matriz correlacion precios

La Figura 4.2.3.E presenta el mapa de calor de las correlaciones de Pearson entre las variables numéricas de precios_mercado. Destacan en rojo intenso la correlación espuria entre spread y precio_medio. En contraste, la celda que cruza precio_medio con volumen_operado aparece en blanco o azul muy tenue ($r \approx -0,02$), confirmando visualmente la independencia entre ambas variables. La columna spread_pct —spread expresado como porcentaje sobre el precio base— rompe la correlación artificial con el precio absoluto y emerge como la medida correcta de volatilidad relativa del mercado.

Decisión para ML — Problema 4: la variable objetivo de los modelos de predicción será spread_pct, no el precio absoluto ni el spread nominal. Dado que la serie temporal cubre únicamente 24 meses (2021–2022), los modelos clásicos de series temporales como ARIMA o SARIMA tienen capacidad de estimación muy limitada por falta de ciclos completos. Se adoptará una estrategia de ventana deslizante con features de lag corto (1, 3 y 6 meses) y validación walk-forward —se entrena con los N meses anteriores y se predice el siguiente período—, con un mínimo de 6 meses de entrenamiento por fold. El uso de K-Fold aleatorio queda descartado para cualquier modelo de series temporales.

Problema 5 — Detección de Anomalías en Producción

Hipótesis de partida: los registros con valores extremos de emisiones o de NDVI (índice de vegetación) son errores de captura que deben eliminarse antes del modelado. El EDA refutó esta hipótesis. Los 67 registros de master_ganadero marcados con flag_emision_extrema = 1 no presentan incoherencia interna: corresponden a explotaciones bovinas reales en las que la combinación de alta carga ganadera y fermentación entérica intensiva genera picos de CH₄ documentados en la literatura científica. Eliminarlos sería precisamente el error: son el tipo de evento que el modelo del Problema 5 debe aprender a detectar. El análisis del dataset imagenes_metadata reveló una segunda naturaleza de anomalía, de tipo espacial. La variable flag_ndvi_anomalo identifica imágenes cuyo índice de vegetación cae fuera del rango histórico del país, señalando posibles episodios de sequía, deforestación o degradación del suelo. Desde el punto de vista del modelado, estas dos familias de anomalía son independientes y requieren aproximaciones distintas: Isolation Forest o One-Class SVM para las anomalías tabulares de emisión (aprenden la frontera del comportamiento normal y señalan lo que queda fuera), y umbral estadístico sobre NDVI o Autoencoder para las anomalías espaciales de vegetación.




Figura 4.2.3.F. Distribución NDVI países

La figura 4.2.3.F nos indica según los valores NDVI presentados de cada país el nivel de salud general de la vegetación.

Todos los países tienen medianas de NDVI por **encima de 0.5** (umbral de vegetación sana), lo que indica que en general las zonas monitorizadas son agrícolas activas, no suelos degradados.

- **India** presenta la caja más estrecha y elevada (~0.65–0.83): vegetación densa y consistente, ideal para modelos de P5. **EE.UU. y Brasil** tienen mayor dispersión (cajas anchas hasta ~0.3), reflejando mayor heterogeneidad territorial (zonas áridas + zonas tropicales en el mismo país).
- Ningún país baja sistemáticamente del umbral 0.2 (suelo desnudo/estrés severo), aunque hay outliers individuales en todos los casos que merecen revisión.

Una limitación a documentar: `imagenes_metadata` incluye registros con fechas hasta 2033, años para los que no pueden existir imágenes satelitales reales. Se interpretan como proyecciones sobre condiciones futuras estimadas. Dado el tamaño reducido del dataset, se opta por mantenerlos como datos válidos asumiendo explícitamente este supuesto.

Decisión para ML — Problema 5: los 67 outliers de emisión se conservan en el conjunto de entrenamiento. El pipeline de anomalías tabulares operará sobre `master_ganadero` con las variables transformadas ($\log_{10}$ aplicado previamente). El pipeline de anomalías

espaciales operará sobre `imagenes_metadata` utilizando las variables de banda espectral (NIR, SWIR) y el propio valor de NDVI como señal primaria. Australia e India, con tasas de validez del 80 % y 72 % respectivamente, se usarán como conjunto de validación preferente para los experimentos iniciales.

Problema 6 — Sistema de Recomendación de Cultivos

Hipótesis de partida: el rendimiento histórico medio de un cultivo en una región es el predictor más relevante para recomendarlo. El EDA confirmó la hipótesis parcialmente, pero añadió dos matices determinantes.

El primero es climático: la variable `dias_con_heladas` actúa como una restricción dura, no como un predictor gradual. En las regiones tropicales del dataset su valor es estrictamente cero; en Rusia o Canadá supera los 100 días. Un cultivo como el Café o la Caña de azúcar es inviable en cualquier región con más de 20 días de helada, independientemente de cuál sea su rendimiento medio histórico. Esta variable debe introducirse en el modelo como filtro previo, no como feature más dentro de un vector de entrada.

El segundo matiz es fitosanitario: el rendimiento esperado de un cultivo debe ponderarse por su riesgo histórico de brotes en la misma región. Para ello, se calculará a partir de `reportes_plagas` una tasa de incidencia histórica por par (cultivo, país), que se incorporará como feature de penalización en el sistema de recomendación. Un cultivo con alto rendimiento medio pero alta tasa de brotes —como el Maíz en Brasil, expuesto al Gusano cogollero— no debería recibir la misma puntuación que uno con rendimiento equivalente y perfil fitosanitario limpio. Finalmente, dado que la variable objetivo `rendimiento_ton_ha` varía en un factor de 15 entre cultivos —la Caña de azúcar supera los 60 ton/ha, el Trigo ronda las 3 ton/ha—, el modelo deberá normalizar el target por cultivo antes del entrenamiento o, alternatively, entrenar modelos independientes por cultivo. No hacerlo introduciría un sesgo sistemático hacia la Caña de azúcar en cualquier modelo de regresión o ranking global.




Figura 4.2.3.G Frecuencias brotes – Pais y cultivos

La figura 4.2.3.G muestra la frecuencia de brotes que genera cada tipo de cultivo en cada país, destacando por ejemplo la frecuencia de brotes en Francia en general en todos

Decisión para ML — Problema 6: el pipeline del sistema de recomendación integrará tres capas: (1) filtrado duro por dias_con_heladas para eliminar cultivos inviables; (2) ranking por rendimiento_medio_pais_cultivo normalizado dentro de cada cultivo; (3) penalización por tasa_incidencia_plagas calculada desde reportes_plagas. La métrica de evaluación será Top-3 Accuracy: el porcentaje de casos en que el cultivo óptimo real figura entre los tres primeros recomendados.

5. RESULTADOS

6. VISUALIZACIÓN (POWERBI)

7. DISCUSIÓN

8. CONCLUSIONES

9. ANEXOS

